Assignment 2 : 辨識冒犯，還是辨識冒犯詞？中文留言分類器的能力與限制

一、研究問題與分類邊界

網絡留言中的負面情緒不一定構成冒犯，提到侮辱字眼也不等於正在侮辱別人。這一次專題以COLD(Chinese Offensive Language Detection)中文冒犯語言資料集為基礎，訓練TF-IDF與邏輯迴歸分類器，考察它能否重現冒犯標籤，以及引用、群體指稱與反偏見表達如何造成冒犯標籤判定的分歧。研究不預設模型只會尋找粗口，而是結合測試結果、詞語貢獻及人工細讀，檢查分類的依據。

以一則完整留言為單位，標籤1代表對個人或群體的侮辱、貶抑等冒犯，0代表非冒犯。判斷時須辨認作者是在實施、認同、轉述還是反對冒犯。批評具體論點或表達不滿不算冒犯；引述他人冒犯言論也不是一定代表不算冒犯留言，因為作者可能認同被引用的辱罵。人工審核另用U表示和記錄語境不足，但模型仍只輸出0/1兩類。

二、資料準備與模型方法

原始資料由COLD公開倉庫取得，使用本次提供的train、dev及test三份CSV，分別有25,726、6,431及5,323則中文網絡留言。合併檢查發現27組去空白後同文異標，將相關文本排除；再去除精確重複、官方test同文及12則已用於規則討論的留言，從官方train每類抽500則。固定種子42，按標籤分層切成800則訓練、200則保留測試。官方dev只參與資料稽核，未用於訓練或調參。

文本採jieba分詞，移除純標點，未作繁簡轉換，也未套用通用停用詞清單，以保留否定等可能有用的線索。TF-IDF把每則留言表示為詞語數值向量，只保留至少出現在兩份訓練文件的詞，使用單詞特徵。邏輯迴歸設定C為1、最多迭代2,000次，分類門檻為0.5。詞彙表與IDF僅由訓練資料學習，避免測試資訊洩漏。

三折交叉驗證只在800則訓練資料內進行，各折重新建立TF-IDF，Macro-F1分別為0.798、0.756及0.823，平均0.792。其後以全部800則訓練最終模型，再評估保留測試集。模型設定固定，沒有看過測試錯誤後調參。三組資料間另以字元三至五元組相似度檢查近重複，在0.65門檻下未找到候選對，但這不能排除所有語意改寫。

三、測試結果與詞語表示的限制

保留測試集兩類各100則，準確率為82%，高於永遠猜同一類的50%基準；Macro-F1為0.819。冒犯類的精確率為0.781、召回率為0.890、F1為0.832。表一顯示，非冒犯被判為冒犯的25則，多於相反方向的11則。這些是與參考標籤的分歧，不宜直接視為已確定的語意誤解。

表一：參考標籤 / 模型預測	非冒犯	冒犯
非冒犯	75	25
冒犯	11	89

例如E01表達對自己參與同性關係的負面感受，原標籤為0，模型卻判1。「男」與「惡心」分別產生約0.637及0.524的正向貢獻。我的初步解讀是模型未分清感受指向自己參與行為，還是對群體的貶低。然而，這是單詞模型，只累加特徵，並未建立兩詞的語法關係；原文其他措辭也可能引起爭議，因此不能將此例當作完全無歧義的證明。

E02描述被侵犯隱私的感受，模型主要受「被」「而」「說」等普通詞推動；E03「你又沒說你用四川話念的」則受「你」「說」「沒」推向冒犯，而「四川話」未進入詞彙表。這表明分類依據不只是粗口。普通詞在訓練樣本中學到的關聯，也可能影響預測，因此不能把正權重當成詞語本身具有冒犯性的證據。

0/1判斷一致也未必代表理解一致。E06「泉州人認為漳州人懶，滑」，我最初判0，原標籤為1，模型判0。但模型詞彙表只保留其中的「懶」「認為」，兩項正貢獻不足以抵消約負0.674的截距。它並不是理解作者在轉述才作此判斷。另一方面，轉述可能傳播或認同偏見，這句沒有明確反對立場，我的判讀本身也需要保留疑問。

四、新文本應用與參考標籤的問題

從未參與建模的官方test，按其他非冒犯、攻擊個人、攻擊群體及反偏見四細類各抽25則，形成100則應用資料。模型與二元參考標籤的一致率為61%，各組如下。樣本刻意平衡且來自同一資料集，不能代表平台自然分布，也不能當成跨平台泛化證據。

表二：原資料細類	與二元標籤一致	比例
其他非冒犯	18 / 25	72%
攻擊個人	16 / 25	64%
攻擊群體	16 / 25	64%
反偏見	11 / 25	44%

反偏見組的低一致率促使我檢查標籤本身。A05自述擔心找不到伴侶、成為「大齡剩女」，我判非冒犯，但質疑它為何被歸為反偏見。提及社會標籤不代表反對該標籤，自述焦慮也不能自動構成糾偏。因此，沒有冒犯與正在反對偏見必須分開。這是細類定義的疑問，不改變此例模型與二元標籤同為0的事實。

A06「你這是討厭公婆，火鍋和四川人背鍋了而已」則把個人衝突與地域群體區分，具有反對不當概括的線索。我曾認為這只是理性糾偏，未達積極反偏見；討論後發現，反偏見不必包含完整的批判理論，糾正群體概括本身也可能成立。不過模型未納入「背鍋」，即使判0，也不能證明它理解這種語用功能。44%只是此組被判為非冒犯的比例，並不是四類反偏見辨識準確率。

五、研究困難、人工審核與反思

最大的困難是界定邊界。我起初以「針對人而非事情」界定冒犯(針對人是冒犯,針對事情是非冒犯)，後來發現批評事件亦可間接羞辱人；反過來，指出某人知識不足也未必構成人格侮辱。反諷、轉述及反偏見與貶抑並存，使簡單規則不足。我將此類留言暫時判定為U，沒有為取得明確答案而補想上下文。

反偏見的分類也令我困惑：最初容易把「沒有冒犯」當成「反偏見」，後來又把反偏見限定為具有強烈批判意識的表達。我的解決方法是分兩步判斷：先辨認留言是否實施或認同貶抑，再尋找它有沒有可辨認的

反對、糾正或辯護對象。A05的個人焦慮沒有明確反對偏見；A06糾正把個人衝突擴大至地域群體的概括，則具有反偏見線索。語境不足時保留U，另記錄與原細類標籤的分歧，不為配合自己的理解而改動測試標籤。

技術理解也是困難。我最初不清楚模型原理，也看不懂普通詞後面的分數代表什麼。透過查核(課程中的lecture notes和AI)，才分清詞語權重、此句TF-IDF與兩者相乘的貢獻值；所有貢獻加截距後，經邏輯函數才得到機率。分數沒有直觀語意，不代表計算錯誤，卻提醒我必須檢查模型實際看到哪些詞，而不能替它編造理解過程。

人工審核包括12則規則試標及28則訓練留言。後28則中，我對21則作明確二元判斷，17則與原標籤一致、4則不同，另7則保留不確定。B13反對以個例概括整體、B26描述語音引起的誤會，我判0而原標籤為1。這些分歧支持查核標籤，卻不足以推算整份資料的錯標率。另有8則測試分歧及6則應用細讀，屬目的性選例，並非隨機評估樣本。這個過程也改變了我的工作方式：先寫出文本證據與信心，再看參考標籤，而不是看到答案後尋找理由支持它。對相互矛盾的判斷保留紀錄，能呈現規則如何修正，也避免把研究中的猶豫隱藏成表面一致。

總結而言，模型能重現部分冒犯分類規律，但詞袋缺少詞序與立場，有限詞彙會遺失重要內容；參考標籤亦可能混淆非冒犯與反偏見。小樣本、同來源應用及未完全排除的近重複，都限制推論。增加有語境的資料、多人獨立標註及在訓練內比較詞組或字元特徵，是後續改進方向(if這是我的Final project的話)。可靠的文本分類不只是提高分數，更要檢查標籤如何定義概念，以及模型憑甚麼作出判斷。

參考資料與

Deng, Jiawen et al.（2022）. COLD: A Benchmark for Chinese Offensive Language Detection. EMNLP, 11580–11599. https://aclanthology.org/2022.emnlp-main.796/ 。

COLD官方資料倉庫：https://github.com/thu-coai/COLDataset 。本次使用學生提供的CSV副本，檔案雜湊與套件版本另存。案例E、A、B的原文及來源記錄編號見review資料夾；正文引文轉為繁體。

AI使用聲明：

本人負責專題方向及計劃的探討與定立、建模來源留言審核、測試案例及測試應用案例，提出分類邊界、詞語分數與反偏見定義的疑問。Codex協助程式、解答專題途中遇到的疑難、資料稽核、模型訓練、結果解釋，並根據本人筆記和討論結果撰寫初稿；本人其後加以修改；報告含 AI協助生成及補充的文字。1000則建模資料沿用原資料集標籤，並非全部由本人和codex重新標註。沒有以事後改標提高測試分數。